Detectarea Titlurilor Înșelătoare (Clickbait) prin Analiza Structurală a Textului și Indexul de Amânare a Informației

Rauliuc Catinca

Cuprins

1 Introducere **2**
1.1 Contextul general al dezinformării online și fenomenul de „clickbait” 2
1.2 Definirea problemei: Discrepanța titlu-conținut 2
1.3 Scopul proiectului și obiectivele cercetării 2

2 Stadiul actual al cercetării (Related Work) **2**
2.1 Metode anterioare pentru detectarea știrilor false pe baza textului 2
2.2 Tehnologii de procesare a limbajului natural (NLP) folosite în prezent . . . 2
2.3 Soluții existente pentru identificarea titlurilor de tip clickbait 2

3 Modelarea părții experimentale **2**
3.1 Datele utilizate 2
3.2 Modelul matematic: Indexul de Amânare a Informației (IDI) 3
3.3 Experimentele propuse 4
3.4 Metodologia de validare și metrici 5

4 Studiu de caz pe date inițiale **6**
4.1 Implementarea algoritmului și mediul de lucru 6
4.2 Efectuarea experimentelor pe un set restrâns 6
4.3 Analiza primelor rezultate 6

5 Validarea pe un set real de date **6**
5.1 Comparația cu abordările din literatură 6
5.2 Evaluarea performanței generale 6

6 Concluzii **6**
6.1 Sinteza rezultatelor și contribuția proiectului 6

1 Introducere

1.1 Contextul general al dezinformării online și fenomenul de „clickbait”

1.2 Definirea problemei: Discrepanța titlu-conținut

1.3 Scopul proiectului și obiectivele cercetării

2 Stadiul actual al cercetării (Related Work)

2.1 Metode anterioare pentru detectarea știrilor false pe baza textului

2.2 Tehnologii de procesare a limbajului natural (NLP) folosite în prezent

2.3 Soluții existente pentru identificarea titlurilor de tip clickbait

3 Modelarea părții experimentale

3.1 Datele utilizate

Pentru realizarea experimentelor, se va utiliza setul de date public *Webis Clickbait Corpus 2016 (Webis-CBC-16)*, recunoscut în mediul academic pentru evaluarea tehnologiilor de detectare a titlurilor înșelătoare.

Arhiva principală a corpusului (corpus-webis-clickbait-16.zip, 266.9 MB) cuprinde 2992 de instanțe (postări extrase de pe platforma Twitter) provenite de la 20 de publicații majore de știri.

Un avantaj semnificativ al acestui set de date constă în etichetarea manuală riguroasă, realizată de trei evaluatori independenți. În baza votului majoritar, 767 dintre instanțe sunt clasificate ca fiind clickbait, formând un „ground truth” stabil pentru antrenarea modelelor. Din punct de vedere structural, datele sunt organizate eficient: directorul `problems` conține metadatele extrase prin API (fișiere `.json`) și pagina web originală (`.html`), în timp ce directorul `truth` conține evaluările centralizate în fișierul `majority.csv`.

Pentru a permite implementarea abordării originale propuse în această lucrare (analiza structurală), datele brute vor suferi o etapă de preprocesare specifică. Spre deosebire de metodele clasice care tratează conținutul articolului ca pe un singur bloc unitar de

text, în cadrul acestui proiect textul va fi segmentat. Astfel, fiecare articol va fi modelat matematic sub forma unei secvențe ordonate de paragrafe individuale: $A = [p_1, p_2, ..., p_n]$, unde n reprezintă numărul total de paragrafe din articolul analizat. Această reformatare este esențială pentru a putea monitoriza poziția informației în text și a calcula ulterior Indexul de Amânare a Informației.

3.2 Modelul matematic: Indexul de Amânare a Informației (IDI)

Abordarea propusă transformă detectarea intenției de tip clickbait dintr-o problemă de clasificare globală a textului într-o problemă de analiză a distribuției spațiale a informației. Pentru a cuantifica matematic acest fenomen, am definit o metrică structurală denumită **Indexul de Amânare a Informației (IDI)**.

Pentru a putea aplica operații matematice, datele textuale trebuie mai întâi vectorizate. Fie T reprezentarea vectorială a titlului (obținută folosind tehnici precum TF-IDF sau Word Embeddings). Articolul segmentat anterior, $A = [p_1, p_2, ..., p_n]$, este transformat la rândul său într-o secvență de vectori corespunzători fiecărui paragraf: $[V_1, V_2, ..., V_n]$.

Primul pas în calculul IDI constă în evaluarea relevanței fiecărui paragraf în raport cu promisiunea făcută în titlu. Aceasta se realizează calculând similaritatea cosinus (Cosine Similarity) între vectorul titlului și vectorul fiecărui paragraf în parte:

$$S(T, p_i) = \frac{T \cdot V_i}{\|T\|\|V_i\|} \tag{1}$$

Aplicând această funcție iterativ, obținem un vector al scorurilor de similaritate semantică pentru întregul articol, care mapează evoluția relevanței textului rând cu rând:

$$S_{articol} = [s_1, s_2, ..., s_n] \tag{2}$$

Pe baza acestei distribuții, definim **Indexul de Amânare a Informației (IDI)** ca fiind distanța relativă (normalizată) la care se află paragraful cu cel mai mare scor de similaritate față de începutul textului:

$$IDI = \frac{\arg\max_i(S_{articol})}{n} \tag{3}$$

Unde:

- $\arg\max_i(S_{articol})$ returnează poziția (indexul i) a paragrafului care a obținut cel mai mare scor de similaritate.
- n reprezintă numărul total de paragrafe din articol.

Interpretarea modelului: Comportamentul acestei metrici izolează perfect tehnica de manipulare structurală. Un scor $IDI \approx 0$ (punctul de maxim se află în primele paragrafe) arată că informația promisă în titlu este livrată cititorului rapid și onest, probabilitatea de clickbait fiind scăzută. În contrast, un scor $IDI \approx 1$ (scorul maxim se află în ultimele paragrafe) demonstrează că informația a fost amânată intenționat până la final pentru a forța cititorul să parcurgă întreaga pagină, indicând un profil manipulativ ridicat.

3.3 Experimentele propuse

Pentru a evalua eficacitatea Indexului de Amânare a Informației (IDI) în detectarea titlurilor de tip clickbait, metodologia de cercetare presupune realizarea a două experimente comparative. Scopul acestora este de a determina ce îmbunătățiri aduce analiza structurală secvențială comparativ cu metodele clasice de procesare a limbajului natural. Această direcție extinde eforturile recente din literatura de specialitate care au utilizat similaritatea cosinus între titlu și conținutul global pentru corpusuri în limba română, precum RoCliCo [1] și SciTechBaitRO [2].

Experimentul 1: Clasificarea globală a textului (Scenariul de control / Baseline)
În acest prim experiment, articolele din setul de date vor fi analizate în mod tradițional. Conținutul fiecărui articol va fi tratat ca un singur bloc unitar de text, ignorându-se structura sa internă — o abordare des întâlnită în sistemele de clasificare care se bazează exclusiv pe distribuția morfologică sau pe extragerea trăsăturilor semantice globale [4]. Se va măsura similaritatea generală dintre vectorul titlului și vectorul întregului corp al articolului. Așteptarea este ca această metodă clasică să fie predispusă la „alarme false", marcând greșit articolele legitime dar lungi, deoarece informația relevantă este diluată într-un text voluminos.

Experimentul 2: Clasificarea bazată pe analiza structurală (Abordarea originală)
Al doilea experiment implementează arhitectura matematică propusă în această lucrare (calculul IDI). Articolul va fi segmentat, se va calcula similaritatea cosinus la nivel de paragraf, iar decizia finală va fi dictată de poziția relevanței maxime. În loc să evalueze doar prezența informației, acest experiment evaluează momentul livrării ei. Această tehnică trece dincolo de o simplă decizie binară, permițând cuantificarea intensității (strength) caracterului înșelător, o necesitate subliniată de cercetători pentru a distinge între diferitele grade de clickbait din mediul online [3]. Astfel, IDI captează manipularea structurală la nivel de discurs, depășind limitele analizelor care tratează documentul ca o entitate statică.

3.4 Metodologia de validare și metrici

Pentru a evalua performanța abordării bazate pe Indexul de Amânare a Informației (IDI) și pentru a o compara cu metoda de clasificare globală, se va utiliza un set standardizat de metrici de evaluare specifice domeniului Machine Learning și procesării limbajului natural.

Întrucât problema este formulată ca o sarcină de clasificare binară (clickbait vs. conținut legitim), performanța va fi măsurată folosind următoarele metrici, derivate din matricea de confuzie (adevărate pozitive - TP, adevărate negative - TN, false pozitive - FP, false negative - FN):

1. **Acuratețea (Accuracy):** Măsoară proporția predicțiilor corecte din totalul instanțelor evaluate. Deși oferă o imagine de ansamblu bună asupra algoritmului, poate fi o metrică înșelătoare dacă setul de date prezintă un dezechilibru major între clase.
2. **Precizia (Precision):** Reprezintă capacitatea modelului de a nu eticheta greșit articolele legitime drept clickbait. O precizie ridicată indică un număr redus de alarme false (False Positives).
3. **Sensibilitatea (Recall):** Măsoară procentul de articole clickbait reale pe care modelul a reușit să le identifice corect (True Positives). Este o metrică crucială pentru a minimiza numărul de articole înșelătoare care reușesc să scape nedetectate (False Negatives).
4. **Scorul F1 (F1-Score):** Calculează media armonică dintre Precizie și Recall, oferind o metrică unică și robustă pentru evaluarea performanței generale. Aceasta este adesea metrica de referință în evaluarea modelelor NLP, deoarece penalizează modelele care favorizează extrem o singură clasă.

Pentru metodologia de validare, setul de date Webis-CBC-16 va fi partiționat folosind tehnica standard de validare încrucișată sau de divizare a datelor (Train-Test Split). Mai exact, se va aloca 80% din volumul de date pentru antrenarea modelelor și optimizarea pragului de decizie pentru IDI, iar restul de 20% va fi păstrat strict pentru faza de testare. Această izolare garantează că evaluarea finală a algoritmului se va face exclusiv pe date neîntâlnite în faza de antrenament, reflectând cu acuratețe capacitatea modelului de a generaliza tiparele de amânare a informației pe știri noi.

4 Studiu de caz pe date inițiale

4.1 Implementarea algoritmului și mediul de lucru

4.2 Efectuarea experimentelor pe un set restrâns

4.3 Analiza primelor rezultate

5 Validarea pe un set real de date

5.1 Comparația cu abordările din literatură

5.2 Evaluarea performanței generale

6 Concluzii

6.1 Sinteza rezultatelor și contribuția proiectului

Bibliografie

[1] Daria-Mihaela Broscoțeanu și Radu Tudor Ionescu. *A Novel Contrastive Learning Method for Clickbait Detection on RoCliCo: A Romanian Clickbait Corpus of News Articles*. In Findings of the Association for Computational Linguistics: EMNLP, 2023.

[2] Raluca-Andreea Gînga și Ana Sabina Uban. *SciTechBaitRO: ClickBait Detection for Romanian Science and Technology News*. In Proceedings of the Third Workshop on NLP for Positive Impact, 2024.

[3] Vijayasaradhi Indurthi, Bakhtiyar Syed, Manish Gupta, și Vasudeva Varma. *Predicting Clickbait Strength in Online Social Media*. In Proceedings of the 28th International Conference on Computational Linguistics, 2020.

[4] Veronika Vincze și Martina Katalin Szabó. *Automatic Detection of Hungarian Clickbait and Entertaining Fake News*. In Proceedings of the 3rd International Workshop on Rumours and Deception in Social Media (RDSM), 2020.